

基于视频预训练的具身智能行为学习方法研究

摘 要

数据是具身智能实现行为学习的关键要素，对驱动具身智能感知、决策及行动控制能力的提升起着重要作用。然而，高质量真实机器人操作数据采集成本高昂、规模较小，互联网视频数据具有数据规模海量和动作交互信息丰富的特点，成为了具身智能数据获取的新途径。但是，该类原始数据缺乏动作状态标签，使得从中精准提取状态特征成为亟待解决的难题。为突破这一瓶颈，本课题构建了一种基于视频预训练的具身智能行为学习方法，聚焦于从无标注视频中提取潜在状态表征，并结合Transformer架构实现具身智能行为学习，有效提升具身智能系统的性能。

本研究主要工作及贡献如下：

1. 视频潜在状态提取方法：针对无标注视频数据中特征混杂的问题，构建了一种“特征提取编码-动静态特征分离-跨帧一致性约束”的基于视频无监督预训练的机器人潜在状态提取方法，从连续视频帧中学习离散化的潜在状态表征，生成紧凑动态特征表示，有效解决了无标注视频数据中状态表征提取困难的问题。

2. 具身智能行为学习方法：针对具身智能系统在任务执行中对多模态信息融合与高效决策的需求，设计一种基于多模态Transformer的具身智能行为学习方法，通过多源输入融合、分块注意力机制和动态动作头，实现跨平台物理特性统一建模与自适应动作生成，显著提升模型在任务执行中的有效性，增强具身智能行为学习的能力。

3. 实验验证与结果分析：为评估方法有效性，在CALVIN和SIMPLER仿真环境以及Franka Emika Panda 7 DoF机械臂实机平台上进行了实验验证。通过与未使用潜在状态的基线策略方法Moto开展定量对比，结果表明，本方法在单一环境任务、未知环境泛化性任务、环境鲁棒性测试以及实机任务中均优于基线方法，平均任务长度和完成率均显著提升，验证所提方法在提升具身智能行为学习方面的有效性。

关键词：具身智能；视频预训练；机器人操作

Research on Video Pre-training Method for Learning Embodied Behaviors

Abstract

Data serves as a fundamental element for embodied intelligence to achieve behavioral learning, playing a crucial role in enhancing perception, decision-making, and motion control capabilities. However, the acquisition of high-quality real-world robotic operation data remains costly and limited in scale. Internet video data, characterized by its vast scale and rich action-interaction information, has emerged as a promising alternative data source for embodied intelligence. Nevertheless, the absence of action-state labels in such raw data poses a significant challenge for extracting precise state features. To address this bottleneck, this study proposes a video pre-training based approach for embodied behavior learning, focusing on extracting latent state representations from unlabeled videos and integrating Transformer architecture to achieve effective embodied behavior learning, thereby improving system performance.

The main contributions of this work include:

1. Video Latent State Extraction Method: To address feature entanglement in unlabeled video data, we developed an unsupervised video pre-training framework featuring "feature encoding - static/dynamic feature separation - cross-frame consistency constraints". This method learns discrete latent state representations from consecutive video frames, generating compact dynamic feature representations that effectively resolve the challenge of state representation extraction from unlabeled videos.

2. Embodied Behavior Learning Method: To meet the requirements of multimodal information fusion and efficient decision-making in embodied systems, we designed a multimodal Transformer-based approach. By incorporating multi-source input fusion, block-wise attention mechanisms, and dynamic action heads, our method achieves unified modeling of cross-platform physical properties and adaptive action generation, significantly enhancing task execution effectiveness.

3. Experimental Validation and Performance Analysis: Comprehensive evaluations were conducted in CALVIN and SIMPLER simulation environments, along with real-world tests on a Franka Emika Panda 7 DoF robotic arm. Quantitative comparisons with the baseline Moto method demonstrate that our approach outperforms in single-environment tasks, unseen environment generalization, robustness testing, and real-robot operations, with significant improvements in average task length and completion rates, validating the effectiveness of our method for embodied behavior learning.

Key Words: Embodied Intelligence; Video Pre-training; Robotic Manipulation

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 机器人策略学习	2
1.2.2 基于视频数据的具身智能行为学习	3
1.3 论文主要内容及结构安排	4
第 2 章 视频预训练学习建模与理论基础	7
2.1 问题描述与建模	7
2.2 相关理论基础	8
2.2.1 SigLIP2 视觉编码器	8
2.2.2 自编码器理论框架	9
2.2.3 对比学习	12
2.3 本章小结	13
第 3 章 基于视频无监督预训练的机器人潜在状态提取	14
3.1 基于视频无监督预训练的机器人潜在状态学习框架	15
3.2 特征解耦与潜在状态提取	15
3.2.1 动-静态特征分离架构设计	15
3.2.2 具身通用性训练策略	18
3.2.3 跨帧一致性约束方法	18
3.3 潜在状态提取重建实验设置及结果	21
3.3.1 潜在状态提取预训练实验设置	21
3.3.2 潜在状态提取重建结果	21
3.4 本章小结	23
第 4 章 基于 Transformer 的机械臂行为学习	24
4.1 基于动作块的机械臂策略	24
4.2 多模态 Transformer 架构设计	25

4.2.1 多源输入融合机制	25
4.2.2 分块注意力 Transformer 机制	27
4.3 机械臂动态动作头行为学习	29
4.4 动作块策略动作输出	30
4.5 本章小结	31
第 5 章 实验验证与结果分析	32
5.1 仿真实验设置	32
5.1.1 CALVIN	32
5.1.2 SIMPLER	33
5.1.3 实验基线 Moto 方法介绍	33
5.2 基于跨帧特征交换的动-静态解耦验证实验	34
5.3 仿真实验结果及分析	36
5.3.1 CALVIN 仿真环境单一场景任务仿真实验结果及分析	36
5.3.2 CALVIN 仿真环境未知场景任务泛化仿真实验结果及分析	38
5.3.3 SIMPLER 仿真环境多任务实验结果及分析	40
5.2.4 SIMPLER 仿真环境对环境变化的鲁棒性实验结果及分析	42
5.4 量化参数对模型性能的影响分析	44
5.5 实机平台搭建	44
5.6 实机验证及结果分析	46
5.6.1 实验说明	46
5.6.2 实机训练数据采集	46
5.6.3 实验结果与分析	47
5.7 本章小结	49
结 论	51
参考文献	52

第1章 绪论

1.1 研究背景及意义

人工智能作为新一轮科技革命的核心驱动力，正在深刻影响着技术革新、经济增长和社会发展的未来趋势。在这一背景下，具身智能（Embodied Intelligence）通过智能体与环境的实时交互来实现知识获取与任务执行，成为连接人工智能与物理世界的关键桥梁。北京市近期发布的《打造全国具身智能创新高地三年行动方案》将具身智能提升至国家战略高度，重点聚焦于“具身大模型和机器人整机的发展”。国际前沿研究如Google的RT^[1]和斯坦福大学的ALOHA^[2]项目，已经展示了具身智能在场景理解、指令解析及技能学习方面的显著进展。这表明，具身智能不仅是我国赢得全球科技竞争主动权的重要战略抓手，也是开展国际科技竞争的前沿领域。

在具身智能的发展演进中，数据、本体和软硬件底座共同构成了其发展的基础。具身智能对数据的依赖性强，高质量的多模态数据是驱动其感知、决策及行动控制能力提升的核心动力。然而当前机器人数据面临双重困境：在质量维度上，高质量机器人操作数据稀缺，现有标注数据集规模难以满足深度模型训练需求，即便是由21个顶尖机构联合构建的大规模数据集Open X-Embodiment^[3]，其数据规模仍难以满足要求；在成本维度上，真实场景数据采集需要巨大空间与人力资源投入，难以实现工业化规模部署。以DORID^[4]数据集为例，其数据采集过程集合50人专业团队耗时12个月，投入成本高达数十万美元。由此可见，缺乏数据成为具身智能能力突破的重要壁垒，具身智能发展亟需探索新的数据获取与利用范式。

而互联网视频数据为突破这一关键瓶颈提供了新路径。海量的互联网视频蕴含着丰富的物理交互信息，其规模化和多样化的特性为构建具身模型提供了宝贵的数据基础^[5]。然而，基于视频数据的具身智能行为学习仍面临两个主要挑战：首先，大部分原始视频数据缺乏明确动作状态标签，难以建立有监督信号，无法从纯视觉信号中提取动作状态相关信息；其次，不同机械臂之间的形态差异导致数据分布异构，致使跨平台具身行为学习困难。因此，如何利用大规模、易获取的视频数据提取具身通用的状态特征，降低对标注数据的依赖，提高具身行为学习能力，成为具身智能领域亟待解决的问题。

综上所述，本课题针对上述挑战，开展基于视频预训练的具身智能行为学习方法研究，旨在利用无标注视频数据，提取潜在状态特征，构建具身智能行为学习模型，提升具身智能系统的性能，推动具身智能技术在实际应用中的发展和推广。

1.2 国内外研究现状

1.2.1 机器人策略学习

具身智能的核心目标是使智能体能够通过感知、决策与行动在物理世界中完成任务。传统的机器人策略学习方法主要依赖于强化学习，在特定任务上取得了显著成果，但在泛化能力和数据利用效率方面仍面临挑战。近年来，基于深度学习的端到端机器人策略学习方法作为实现这一目标的关键技术，受到了广泛关注。机器人策略学习旨在通过训练端到端模型使机器人能够根据环境状态和任务目标，生成合理的动作策略，以完成各种操作任务。随着人工智能技术的发展，基于深度学习的端到端机器人策略学习方法逐渐成为主流研究方案。

一种路线是基于经典Transformer的序列建模方案，利用序列建模问题结构的自然对齐性，依靠Transformer模型强大的序列处理能力进行建模，能够很好地捕捉状态好动作之间的依赖关系，模型可以根据过去的状态和动作序列，预测未来的最优动作^[6-7]。例如，RT-1^[1]通过端到端框架实现了多模态数据融合，接受语言指令和视觉信息，利用FiLM技术进行特征对齐，最终输出机械臂位姿、夹持状态等动作指令。ALOHA^[2]项目中提出的动作分块（Action Chunking with Transformer, ACT）算法基于条件变分自编码器架构，通过Transformer编码器处理视觉输入并生成动作序列，在精密操作任务中展现出优异的性能，仅需少量演示数据即可实现高成功率控制。然而，这类方法在生成动作时受到模型自身架构限制，依赖高质量的状态-动作配对数据，且模型泛化能力受限于训练数据的覆盖范围，导致动作生成的准确性和多样性受限。

另一种主流方案是基于预训练大语言模型和视觉语言模型^[8]，利用预训练模型强大的多模态表征能力处理视觉与语言输入，并生成相应的动作序列。这类方法继承大规模预训练知识，显著提升了机器人的语义理解与复杂推理能力。例如RT-2^[9]通过将PaLI-X和PaLM-E等通用多模态模型适配于机器人领域，实现了零样本迁移、语义逻辑解析和多步推理等技术突破。OpenVLA^[10]作为开源VLA模型，以7B参数规模在Open-X Embodiment^[3]机器人数据集上训练，结合SigLIP^[11]和DINOv2^[12]视觉编码器，

并支持高效微调和量化部署。 π_0 模型^[13]则采用预训练的视觉语言模型作为骨干网络，通过流匹配技术生成连续动作分布，能够处理高达50Hz的高频动作，从而实现精准流畅的复杂操作技能。尽管基于预训练模型方案能够在未见过的任务和数据上展现出一定的泛化性，但动作生成受限于预训练模型的固有偏差，可能导致输出动作的准确性与多样性不足。

还有一类基于扩散模型的方案，将机器人动作生成策略建模为去噪扩散概率模型，通过逐步去噪的过程生成动作，擅长处理高维多模动作分布。Diffusion Policy^[14]将机器人视觉运动策略表示为条件去噪扩散过程，通过扩散模型逐步将噪声去噪为动作，有效地处理多模态动作分布、适应高维动作空间，提升训练的稳定性。RDT^[15]则针对双臂协同任务优化，旨在解决双臂操作策略中协调机械臂的复杂性和训练数据的稀缺性的挑战，能够有效表示多模态动作，捕捉双臂机器人数据的非线性和高频特性。 $\pi_{0.5}$ ^[16]模型则采用了基于 π_0 模型^[13]的改进方案，通过在预训练阶段使用离散动作表示进行训练，然后在后训练阶段引入流匹配动作专家来生成连续动作，结合了离散表示训练的高效性和连续动作表示在推理时的灵活性，能够更好地处理复杂的动作序列。尽管扩散模型处理动作分布多模态时表现出色，但其在生成动作时可能受到噪声的影响，导致动作的准确性和稳定性受到影响。

上述方法在动作生成的准确性、多样性等方面仍存在局限性，且严重依赖于带有真值动作标签标注的交互式数据，这大大限制了机器人策略模型的可扩展性。

1.2.2 基于视频数据的具身智能行为学习

近年来，随着机器人领域数据的稀缺以及互联网视频数据的爆炸式增长和视觉学习技术的突破，利用视频数据进行机器人策略学习已成为具身智能领域的重要研究方向。视频数据提供了丰富的物理动力学知识，成为机器人策略学习的理想选择。

早期研究主要利用对比学习和以自我为中心的视频数据，以增强机器人操作的视觉表征能力。R3M^[17]利用Ego4D^[18]人类视频数据集，通过时间对比学习和视频-语言对齐进行预训练，得到的视觉表示可作为下游机器人操作任务的冻结感知模块，提升数据效率和任务成功率。VIP^[19]通过将人类视频中的表示学习建模为离线目标条件强化学习问题，预训练后能够为目标图像指定的下游机器人任务提供有效的视觉奖励和表示。然而，这类方法存在一些显著的缺点，难以捕捉与机械臂操作直接相关的

动态特征，而且表征与具体任务目标存在语义鸿沟，影响机械臂具身行为学习的性能。

另一些研究生成视频或图像作为高级规划器指导低级动作生成策略。SuSIE^[20]利用预训练的图像编辑扩散模型在视频数据上微调，生成给定当前观察和语言指令下的未来“子任务目标”观察。同时使用带动作标签的机器人数据训练底层动作条件生成策略。UniPi^[21]将文本引导的视频生成作为通用策略，使用基于扩散模型的视频生成器作为规划器，根据初始帧和文本描述生成视频轨迹，然后通过逆动力学模型从生成的视频中提取动作。该方法利用文本作为任务描述的通用接口，视频作为不同环境中的通用行为表示。这类方法生成内容与实际环境存在差异，导致底层动作控制器基于不准确的中间指导信息执行动作，影响操作的精确性和成功率。

最新研究已经转向采用生成式视频预训练方法，然后利用机器人数据进行微调来训练端到端的策略模型。例如Escontrela等人^[22]使用视频帧的像素值或图像块级标记作为其预训练目标，预先训练了一个自回归视频预测模型，为强化学习提供奖励信号。Genie^[23]提出了对大规模视频中的潜在动作进行无监督学习，以创建一个多功能的2D游戏模拟器。同时，Ye等人^[5]通过预训练策略模型来预测未来的一步潜在动作，而Chen等人^[24]则将潜在动作作为低级策略的中间目标。相比之下，本研究侧重于从视频中提取具身通用的运动表征，同时解耦动-静态信息，提高具身行为学习能力。

相比之下，本研究侧重于从视频中提取具身通用的潜在状态表征，同时解耦动-静态信息，提高具身行为学习能力，充分利用了视频数据中的潜在状态特征，有效解决了现有方法的局限性。

1.3 论文主要内容及结构安排

为了突破具身智能策略学习规模化应用中的数据瓶颈，充分利用视频中的无标签交互数据，进一步提升具身智能系统学习能力，本课题构建了一种基于视频预训练的具身智能行为学习方法，通过从无标注视频中提取具身通用的潜在状态表征，并结合Transformer架构实现具身行为学习，有效降低对标注数据的依赖，提升具身智能系统的学习能力。具体而言，本课题首先设计了一种基于视频无监督学习的机器人潜在状态提取框架，通过动-静态特征解耦和跨帧一致性约束，从无标签视频中提取具身通用潜在动态表征的紧凑表示；其次，设计了一种基于Transformer的具身行为技能学习方法，基于多模态Transformer架构，以潜在动态特征作为核心输入，通过引入机械

臂类别嵌入层和动态动作头架构，实现不同机械臂物理特性的统一建模；最后，在实验验证与分析部分，基于公开数据集和基准在仿真实验中验证了该方法在任务中的准确性和鲁棒性，同时在实机平台上验证了方法的有效性。

如图1-1所示，本研究根据内容结构本文共划分为五个章节。第1章即本章介绍了目前机器人领域研究的背景，简要阐述本课题的研究背景和研究意义，通过介绍机器人策略学习、基于视频数据的具身智能行为学习等领域的国内外研究现状，进而明确了本课题的研究内容和思路。其他章节安排具体如下：

第2章 视频预训练学习建模与理论基础。本章首先对基于视频的机器人技能学习问题进行形式化建模，定义输入与输出的映射关系，为后续方法设计奠定基础。随后详细介绍了SigIP2视觉编码器、自编码器理论框架以及对比学习等核心技术原理，为视频预训练和多模态条件动作生成提供理论支撑。

第3章 基于视频无监督预训练的机器人潜在状态提取。本章提出一种编码器-解码器架构，通过自监督学习框架，结合动-静态特征解耦和跨帧一致性约束，从连续视频帧中学习离散化的具身通用的潜在状态表征。实验表明，该方法能有效分离环境中的静态背景与动态操作信息，为后续行为学习提供鲁棒且具身通用的输入特征。

第4章 基于Transformer的机械臂行为学习。本章提出一种多模态Transformer架构，融合语言指令、视觉观察和机器人潜在状态并协同推理，通过动态动作头架构将通用技能表征适配到具体机械臂，实现不同机械臂物理特性与任务需求的统一，显著提升模型在具身实体场景下的适应性。

第5章 实验验证与结果分析。本章针对基于视频预训练的具身智能行为学习方法进行了验证。在CALVIN和SIMPLER仿真环境以及Franka Emika Panda 7 DoF机械臂平台上，对所提方法进行实验验证。实验结果表明，该方法在单一场景任务、未知场景泛化任务、环境鲁棒性测试与实机实验中均优于未使用潜在状态的基线方法，平均成功率显著提升，验证了方法的有效性和实用性。




图 1-1 论文结构安排

第2章 视频预训练学习建模与理论基础

本章旨在为基于视频预训练的具身智能行为学习方法提供理论基础与建模框架。首先对基于视频的机器人技能学习问题进行形式化建模，明确定义了从视频输入到技能表征和动作策略输出的映射关系。在此基础上，介绍了SigLIP2^[25]视觉编码器、自编码理论框架以及对比学习方法的理论基础，为后续提出的机器人潜在状态提取框架和具身行为学习模型提供理论基础。

2.1 问题描述与建模

基于视频的机器人具身行为学习旨在从无标签视频数据中提取有价值的信息，以实现机器人对具身行为的有效学习。本节将对这一问题进行形式化建模，明确输入输出的映射关系，为后续方法的设计奠定基础。

首先，给定一组来自不同具身实体的无标注操作序列 $V = \{v_1, v_2, \dots, v_N\}$ ，其中每个视频 $v_i = (x_1^i, x_2^i, \dots, x_K^i)$ ， K 为视频的总帧数，表示在第 i 个机器人操作视频的观测，视频帧为 $x_t^i \in \mathbb{R}^{H \times W \times 3}$ ， (H, W) 为原始图像分辨率。这些视频包含了丰富的视觉信息和潜在的运动模式，模型目标是学习一个通用表征函数 f_θ 和策略函数 π_ϕ ，使得

$$f_\theta : (x_{t-k:t}, r_n) \rightarrow z_t \quad (2-1)$$

$$\pi_\phi : (T, z_t, r_n) \rightarrow a_t \quad (2-2)$$

其中 $z_t \in \mathbb{R}^d$ 表示时间步 t 的潜在状态表征， d 表示潜在状态空间维度， $r_n \in \mathbb{R}^m$ 表示机械臂类型嵌入， T 表示任务语言描述， $a_t \in \mathbb{R}^n$ 表示机械臂动作， k 表示观测历史窗口大小。

为构建清晰的框架，本研究定义视频重建损失函数：

$$L_{recon} = \mathbb{E} \left[\| G_\psi(z_t, r_n) - x_t \|_2^2 \right] \quad (2-3)$$

其中 G_ψ 是条件解码网络，机械臂类型嵌入 r_n 通过可学习的查找表获得， $r_i = \text{Embedding}(\text{type}_i), \text{type}_i \in \{1, \dots, R\}$ ， R 是机械臂类型总数。这种设计使得模型能够显式地区分不同机械臂的动力学特性。

通过上述建模，本节为基于视频的机器人技能学习提供了一个清晰的框架，明确了从视频输入到技能表征和动作策略输出的映射关系，为进一步的方法设计和实现提供了理论基础。

2.2 相关理论基础

2.2.1 SigLIP2 视觉编码器

随着人工智能技术的发展，视觉-语言模型（Vision-Language Models, VLMs）在多模态任务中扮演着越来越重要的角色，通过结合图像和文本信息，能够实现零样本分类、图像-文本检索以及视觉问答等复杂任务。其中，对比式图像-文本嵌入模型（如CLIP^[26]和ALIGN^[27]）通过在大规模数据集上进行训练，取得了显著的成果。然而，这些模型在定位任务以及密集特征提取等方面仍有提升空间。为了克服这些局限性，SigLIP2^[25]在继承SigLIP^[11]的基础上，通过引入多种改进技术，显著提升了模型的性能和适用性。

SigLIP2的核心方法在于其独特的训练策略和架构设计。如图2-1所示，该模型通过结合多种先进的训练技术，如基于解码器的预训练、自监督损失（包括自蒸馏和掩码预测），以及在线数据整理，实现了对图像和文本的深度语义理解。具体来说，SigLIP2在训练过程中首先采用基于解码器的预训练，通过引入一个标准的Transformer解码器，模型能够学习生成图像描述和自动指代表达预测，从而提升对图像区域的定位能力。

此外，自监督损失的引入进一步增强了模型对密集特征的提取能力，这对于分割、深度估计等任务至关重要。通过自蒸馏和掩码预测，模型能够更好地学习局部语义信息，从而在全局语义和密集任务之间取得平衡。具体来说，在SigLIP2中，自蒸馏通过构建一个教师网络和一个学生网络来实现。教师网络的参数是通过指数移动平均（Exponential Moving Average, EMA）的方式从学生网络的参数中获得的。具体来说，教师网络接收完整的图像作为输入，而学生网络则接收图像的局部视图。学生网络的目标是学习匹配教师网络的全局表示，这一过程通过一个单独的多层感知机（MLP）头来实现。通过这种方式，自蒸馏能够促使学生网络学习到更丰富的局部语义信息，从而提升模型在密集任务中的表现。掩码预测是另一种自监督学习技术，通过随机掩盖图像的部分区域，并训练模型预测这些被掩盖区域的特征。在SigLIP2中，掩码预测通过将图像的一部分嵌入替换为掩码标记，然后训练学生网络匹配教师网络在这些掩码位置的特征。这种技术能够进一步强化模型对局部特征的学习能力，提升模型在密集任务中的性能。

为了支持多分辨率和保持输入图像的原始宽高比，SigLIP2还引入了NaFlex变体。这种变体结合了FlexiViT和NaViT的思想，能够在处理不同类型的图像时，根据图像的原始宽高比调整输入分辨率，从而减少因宽高比失真而导致的性能下降。这一特性使得SigLIP2在处理文档理解等对宽高比敏感的应用时表现更为出色。在实际应用中，SigLIP2的视觉编码器被广泛用于提取视觉特征。这些特征不仅能够为后续的多模态任务提供丰富的语义信息。




图 2-1 SigLIP2 网络结构图

2.2.2 自编码器理论框架

在机器学习领域，无监督学习中如何学习到有用的表征一直是一个关键挑战。传统的变分自编码器（Variational Autoencoder, VAE）通过学习连续的潜在变量来生成数据，但在面对强大的自回归解码器时，往往会遇到“后验坍塌”的问题，即潜在变量被忽略，模型退化为仅依赖解码器生成数据。为解决这一问题，向量量化变分自编码器（Variational Quantized Variational Autoencoder, VQ-VAE）^[28]巧妙地将变分自编码器VAE^[29]的框架与离散表征相结合，通过向量量化（Variational Quantization, VQ）技术，在自编码器的特征隐空间中学习离散化的表征，使得模型能够学习离散的潜在变量。




图 2-2 VQ-VAE 网络结构

VQ-VAE 的网络架构如图 2-2 所示，其包括三个组成部分编码器 E 、解码器 G 和码本。码本 e 包含 K 个离散的可学习的潜在向量 $\mathbf{e}_k \in \mathbb{R}^n, k \in 1, 2, \dots, K$ 。对于输入图像 $\mathbf{I} \in \mathbb{R}^{H \times W \times 3}$ ，编码器 E 提取其连续的潜在空间的图像特征 $\mathbf{F} = E(\mathbf{I}) \in \mathbb{R}^{h \times w \times n}$ 。然后对于图像特征 $\mathbf{F}$ 的每一个连续特征向量 $\mathbf{f} \in \mathbb{R}^n$ ，VQ-VAE 通过向量量化操作，将连续特征映射到潜在变量 $\mathbf{e}_k$ ，具体而言，通过查找码本 e 中与最近的向量 $\mathbf{e}_k$ 来实现这一过程：

$$\mathcal{Q}(\mathbf{f}) = \arg \min_{k \in [K]} \|\mathbf{f} - \mathbf{e}_k\|_2 \quad (2-4)$$

原始图像特征的每一个连续特征均通过以上方式映射到离散潜在空间，然后查找到的离散码本向量通过解码器 G 中解码回原始数据空间重构图像。在训练过程中，VQ-VAE 模型的总损失为重构损失、码本损失以及量化损失的总和：

$$\mathcal{L} = \|\mathbf{I} - \hat{\mathbf{I}}\|_2^2 + \|\text{sg}[E(\mathbf{I})] - \mathbf{e}\|_2^2 + \beta \|E(\mathbf{I}) - \text{sg}[\mathbf{e}]\|_2^2 \quad (2-5)$$

式中，第一项为重构损失，第二项码本损失中的 sg 是一个梯度停止运算符，即通过直通梯度估计器^[30]将解码器的梯度直接传递给编码器。第三项量化损失中的 β 是损失权重。

VQ-VAE 设计的三种损失函数分别对应着不同的优化目标。第一项重构损失旨在确保模型能够尽可能精确地重建输入数据，保留输入数据的关键特征。第二项码本损失专注于优化码本中的潜在向量，这些潜在向量是特征隐空间中的聚类中心，对于离散表征的学习至关重要。最后，量化损失的作用是促使每个特征向量向其最近的潜在向量靠拢，同时防止特征向量的值过大，从而增强模型的稳定性和鲁棒性。通过这种

RQ-VAE通过学习数据的多层离散表征,显著提升了模型对于细粒度特征的表征能力。Lee等人^[31]进一步设计了RQ-Transformer,负责自回归地预测RQ-VAE提取的隐空间代码。它由空间Transformer和深度Transformer组成。空间Transformer通过掩码自注意力块提取上下文向量,总结前一位置的信息;深度Transformer则基于上下文向量预测下一个位置的隐空间变量。这种设计使得RQ-Transformer能够有效地学习和预测RQ-VAE提取的代码,同时显著降低了计算成本。

2.2.3 对比学习

对比学习(Contrastive Learning)^[33]作为一种新兴的自监督学习方法,在机器学习领域,尤其是无监督学习中,近年来受到了广泛关注。在对比学习中,模型通过对比不同输入样本之间的关系来学习数据的表征,这与传统的判别模型和生成模型有显著区别。判别模型侧重于学习输入数据与(伪)标签之间的映射关系,而生成模型则致力于重建输入样本本身以学习表征^[34]。相比之下,对比学习通过比较不同输入样本来学习表征,而不是仅仅从单个数据样本中提取信息。

在对比学习中,学习过程是通过比较正样本对(“相似”输入)和负样本对(“不相似”输入)来实现的。这种方法不需要为每个输入样本 $\mathbf{x}$ 提供人工标注的标签 y ,而是通过定义相似性分布来采样正输入 $\mathbf{x}^+ \sim p^+(\cdot|\mathbf{x})$ 和负输入 $\mathbf{x}^- \sim p^-(\cdot|\mathbf{x})$ 对比学习的目标是将“相似”样本的表征拉近,而将“不相似”样本的表征推远,从而在嵌入空间中形成清晰的区分。在自监督学习过程中,对比学习方法不像其他需要在学习过程中调整模型架构和参数的自监督方法,其不依赖于真实标签或伪标签,而是根据输入数据之间的相似性定义来学习数据表征。这种相似性基于数据本身的特性,不需要真实标签对或伪标签,从而避免了监督学习中仅依赖有限标签对的局限性,并且更加简洁有效。

如图2-4所示,输入样本首先通过编码器映射到一个共享的潜在空间,在该空间各个样本之间的距离表示他们的相似程度,即相似样本的表示被拉近,而不相似样本的表示则被推远。具体而言,对比学习过程通过对比正负样本对的表征来实现,训练目标是最大化正样本对之间的相似度,同时最小化负样本对之间的相似度^[35],包括以下几个关键步骤:首先,利用数据增强技术对原始数据进行处理,生成正样本。例如,在图像数据中,可以通过随机裁剪、颜色失真等操作生成正样本对。这些正样本对在语义上是相似的,但在具体的像素级别上存在差异。接着进行负样本选择,负样

本通常从数据集中随机选择，与正样本形成对比。负样本的选择策略对于对比学习的效果至关重要，因为它们提供了学习过程中所需的“负”监督信号。然后正负样本通过一个共享权重的特征提取网络，将输入样本映射到一个高维的对比空间中，以提取它们在对比空间中的特征表示。




图 2-4 对比学习流程图

从形式上讲，对比学习的过程可以有下面公式简要表示：

$$\theta^*, \omega^* = \arg \min_{\theta, \omega} \mathcal{L}_{\text{con}} \left(p_{\omega} \left(f_{\theta} \left(\tilde{\mathcal{D}}^{(1)} \right), f_{\theta} \left(\tilde{\mathcal{D}}^{(2)} \right) \right) \right) \quad (2-6)$$

其中， $\tilde{\mathcal{D}}^{(1)}$ 和 $\tilde{\mathcal{D}}^{(2)}$ 是正负样本生成的数据视图。 $f_{\theta}(\cdot)$ 是共享编码器，用于学习正负样本对应视图。 $p_{\omega}(\cdot)$ 是解码器估计正负样本在对比空间之间一致性的。 $\mathcal{L}_{\text{con}}$ 表示优化目标对比损失函数。

2.3 本章小结

本章系统性地介绍了基于视频预训练的的机器人技能学习理论基础，并阐述了相关核心技术原理。首先，通过形式化建模明确了输入与输出，为后续机械臂具身行为学习模型构建提供了理论基础，以及介绍在视频预训练、多模态条件动作生成环节中所需要的一些理论知识，包括SigLIP2视觉编码器、自编码器理论框架和对比学习。

第3章 基于视频无监督预训练的机器人潜在状态提取

本章的主要内容为基于视频无监督预训练的机器人潜在状态提取方法，首先对框架设计与构建方法展开介绍，指出模型组织构建形式，之后从特征解耦与潜在状态提取、实验设置及重建结果两个方面对本章设计的方法进行阐述，旨在从连续视频帧中提取具身通用的潜在状态，支持训练后续具身策略模型。如图3-1所示，本框架基于自动编码器设计，包含三个核心模块：

（1）编码器：采用预训练的视觉编码器提取帧间共享的视觉特征，实现动-静态特征的显式分离，其中动态分支专注于机械臂-物体交互，而静态分支编码环境不变特征；

（2）RQ-VAE^[31]：通过残差向量量化技术，将动态特征量化为有限的潜在动态状态；

（3）解码器：通过交换连续帧的静态特征组合重建，实现基于潜在状态的跨帧条件图像生成，确保动-静态特征分离的有效性。

本章将对每个模块方法进行详细阐述与分析。




图 3-1 基于视频无监督预训练的机器人潜在状态提取框架

3.1 基于视频无监督预训练的机器人潜在状态学习框架

基于视频的机器人无监督潜在状态学习可以形式化为一个多模态序列建模问题。给定来自不同的具身对象的无标注操作视频序列，从一对连续的视频帧开始，提取源帧和目标帧对，表示为 $\{o_t, o_{t+k}\}$ ，由帧间隔 k 分隔。为了确保不同数据集之间大约1秒的均匀时间间隔，帧间隔根据每个数据集特有的记录频率进行校准。为了从视频中提取潜在状态，本研究模型是基于编码器 $E(s_t, d_t | o_t)$ 和解码器 $D(o_t | s_t, d_z)$ 构建的。

利用预训练的编码器根据连续的视频帧提取潜在动态和静态特征 $E(s_t, d_t | o_t)$ ， $E(s_{t+k}, d_{t+k} | o_{t+k})$ 。为了进一步压缩信息，本课题对动态特征应用了向量量化方法，将动态特征 d_t 量化为潜在动态特征 $d_z \in \mathcal{R}^{N \times d}$ ，以RQ-VAE为目标进行优化，码本大小为 $|C|$ 。此外加入可学习的机械臂类型嵌入 r_n ，这种设计使得模型能够显式地区分不同机械臂的动力学特性。解码器是一个基于ViT^[36]架构的潜在状态解码器，旨在利用量化的潜在动态特征以及静态特征实现对当前视频帧的有效重建。为确保特征解耦的完备性，研究设计了双向特征交换验证机制，并引入多级损失约束。具体操作为：将源帧与目标帧的静态特征进行交换，并将交换后的特征输入解码器进行强制重建 $D(o_t | s_{t+k}, d_z, r_n)$ ， $D(o_{t+k} | s_t, d_{z+k}, r_n)$ 。由于静态特征需具备帧间不变性，因此重建图像应与原始图像保持高度一致。为实现这一目标，构建了一个包含重建损失、感知损失、特征匹配损失及量化损失的四重损失体系，从而保证动静态信息的有效解耦。

3.2 特征解耦与潜在状态提取

3.2.1 动-静态特征分离架构设计

有效的特征解耦对于实现从无标注视频数据中提取可泛化的机器人潜在状态至关重要，通过将视频帧中的环境信息（静态特征）与机械臂操作相关的动态变化（动态特征）进行分离，过滤无关信息，才能提取更具本质和通用性的潜在动态状态。本研究架构设计基于RQ-VAE模型^[31]，包含三个核心层级：特征提取层、特征解耦层和量化重建层。

特征提取层基于预训练的SigLIP2^[25]构建，以原始视频帧 $x_t \in \mathbb{R}^{H \times W \times 3}$ 作为输入，通过冻结的视觉编码器提取图像块特征：

$$f_t = \text{SigLIP2}(x_t) \in \mathbb{R}^{N \times D} \quad (3-1)$$

其中 N 为图像块数量，本研究选取 $N = 49$ ， $D = 1024$ 为特征维度。

采用冻结视觉编码器既保留了强大的视觉表征能力，又避免了在训练初期破坏在巨量互联网图像数据上已学习到的视觉先验，保留空间-语义信息。具体而言，图像首先通过预训练的SigLIP2的图像编码器进行编码标记化，得到从图像中提取到的特征 f_t 。这一过程为后续特征解耦提供了丰富的视觉特征基础。




图 3-2 特征提取与特征解耦示意图

特征解耦层通过改进的M-Former实现，本课题设计了57维可学习的查询向量，与视觉编码器提取到的特征 f_t 拼接后作为M-Former的输入。相较于传统视频编码需要大量标记来表征完整视觉信息导致知识嵌入稀疏的问题，这种基于查询向量的设计通过紧凑的嵌入空间高效捕捉跨帧的视觉动态变化。为了增强特征的表达能力，在M-Former中引入了位置编码、类型编码以及分隔标记等嵌入信息，构成了丰富表征，其中位置编码为序列中的每个位置提供空间信息，类型编码则区分不同来源的输入特征。这些查询向量在M-Former中通过自注意力机制进行交互，其输出特征被显式划分为静态特征和动态特征。这种机制能够将机器人操作视频中的时序相关性压缩为紧凑的潜在表征，提高了动态特征的表达效率。具体而言，模型通过查询向量引导

的注意力机制，分别提取背景、物体初始状态等低变化特征和机械臂运动、物体位姿变化等高变化特征。特征提取层与特征解耦层框架如图3-2所示。




图 3-3 残差量化变分自编码器示意图

量化重建层对解耦后的特征进行处理：动态特征通过RQ-VAE^[31]进行多级残差量化，采用从粗到精的离散化策略。如图3-3所示，每级量化计算当前残差与码本的距离，选择最近的码本向量作为量化结果并迭代更新残差，最终得到高度压缩的离散动态表征。如图3-4所示静态特征和量化后的动态特征分别通过各自的降采样通路处理后再进行特征融合，最后通过上采样器恢复至解码器所需维度参与图像重建。这种设计既确保了动态特征的离散化表示，又保持了静态特征的连续性，为后续的跨机械臂技能学习提供了紧凑通用的特征空间。




图 3-4 动-静态特征分离架构设计总框架图

3.2.2 具身通用性训练策略

机器人操作任务中，不同机械臂的外观和动力学特性等配置存在差异，这导致了机械臂在执行相同任务时的动作表现和运动学特征各不相同。然而，从任务执行的角度来看，不同机械臂的目标和任务逻辑是相同的，即它们需要完成的操作任务的本质是一致的。因此，提取具身通用的动态特征对于实现跨平台的具身行为学习至关重要。

为增强方法在跨平台场景下的适用性，本方案在特征交换机制中整合了机械臂类型编码的协同处理。为每种机械臂（Franka, UR, Google, WidowX等）分配一个可学习的嵌入向量，作为模型输入的额外条件。在训练时，4维的可学习机械臂类型编码会与潜在动静态特征拼接后共同输入解码器，形成条件式重建。这种设计使得量化动态特征能自动适配目标机械臂的动力学特性，能够在跨具身实体任务中展现出显著优势。

通过加入机械臂类型嵌入，模型能够学习到一个通用的、与具身实体类型无关的动态特征空间。在该空间中，不同机械臂执行相同任务时的动态特征表示是相似的，从而实现了具身通用性。具体来说，机械臂类型嵌入为模型提供了一个关于具身类型的显式信息，使得模型能够区分不同机械臂的动力学特性，并在特征提取过程中自动调整和补偿这些差异。这样，提取到的动态特征就不再依赖于具体的机械臂外观和硬件配置，而是反映了操作任务本身的本质特征。

3.2.3 跨帧一致性约束方法

（1）数据增强：

本研究数据集构建采用多模态时空增强框架，提出动态跳跃采样策略，有效解决固定采样间隔在机器人操作场景中的局限性。模型通过参数化控制采样间隔实现增强机制：首先，为了确保不同数据集之间大约1秒的均匀时间间隔，帧间隔根据每个数据集特有的记录频率进行校准；其次，动态跳跃间隔生成：在基础采样间隔基础上，引入最大帧间隔参数构建随机区间采样，实现时间步长的概率分布，显著增强模型对非匀速操作场景的适应能力，同时确保了模型学习到的静态特征和动态特征在时序上具有一定鲁棒性，而不是简单地记忆时序模式。

（2）帧间特征交换机制：

基于前文构建的动-静态特征分离架构，本研究进一步设计了跨帧一致性约束方法以强化特征解耦的鲁棒性。该方法的核心在于建立帧间特征交换机制：如图所示，该方法首先对连续视频源帧 O_t 和目标帧 O_{t+k} 分别提取各自动态静态特征 $s_t, d_t, s_{t+k}, d_{t+k}$ ，并得到各自的量化误差 $\mathcal{L}_{quant_1}$ 、 $\mathcal{L}_{quant_2}$ ，这些量化参数不仅用于后续重建，更作为特征解耦程度的显式度量指标。

在特征交互阶段，本课题采用双路径验证策略：通过解码器将源帧和目标帧的量化动态特征与静态特征联合解码，生成基准重建结果 $\hat{O}_t, \hat{O}_{t+k}$ ；而交换路径则刻意打破时序关联，将目标帧的静态特征 s_{t+k} 注入源帧的量化动态特征 z_t 进行交叉解码，同时将源帧的静态特征 s_t 注入目标帧的量化动态特征 z_{t+k} 进行反向解码，得到 $\hat{O}_{t,swapped}, \hat{O}_{t+k,swapped}$ 。

这种强制特征跨帧迁移的设计，迫使模型必须满足两个关键约束：一、静态特征必须具备帧间不变性，保证交换后动态特征仍能正确解码；二、动态特征必须包含完整时序信息，确保跨帧迁移后仍能保持运动逻辑连贯。特别地，机械臂类型作为条件编码信息，注入静态和动态特征空间，确保模型学习到的潜在状态是与具身通用的，需结合机械臂类型才能准确重建出与具身实体相关的机械臂操作图像。

（3）解码验证：

解码验证步骤得到动态量化特征 z_t 和静态特征 s_t ，先分别经由各自的上采样器升为至解码器维度。然后二者被输入至解码器中的多层Transformer编码器，通过多头自注意力机制捕捉全局依赖关系，然后通过卷积层进行非线性特征变换，并借助残差连接与层归一化稳定训练过程，最终输出重建后的当前视频帧 $\hat{O}_t$ 。

损失函数模块采用多维度协同优化策略，构建四重损失体系强化动态特征解耦能力。首先计算重建损失 $\mathcal{L}_{recons}$ ：基于L2范数，分别计算原始路径 $\hat{O}_t, \hat{O}_{t+k}$ 和交换路径 $\hat{O}_{t,swapped}, \hat{O}_{t+k,swapped}$ 与真值的像素级重建误差 $\mathcal{L}_{recons,ori}, \mathcal{L}_{recons,t,swapped}$ 。具体而言，重建损失通过以下公式计算：

$$\mathcal{L}_{recons_ori} = F.mse(O_t, \hat{O}_t) + F.mse(O_{t+k}, \hat{O}_{t+k}) \quad (3-2)$$

$$\mathcal{L}_{recons_swapped} = F.mse(O_t, \hat{O}_{t,swapped}) + F.mse(O_{t+k}, \hat{O}_{t+k,swapped}) \quad (3-3)$$

$$\mathcal{L}_{recons} = 0.5 \cdot \mathcal{L}_{recons_ori} + 0.5 \cdot \mathcal{L}_{recons_swapped} \cdot \lambda_{Swapped_Property} \quad (3-4)$$

其次引入感知损失，通过对比重建帧与真实帧的感知距离，强化高维语义保真度，得到原始路径和交换路径的感知损失 $\mathcal{L}_{perceptual}$ ， $\mathcal{L}_{perceptualswapped}$ 。感知损失的计算通过 LPIPS（Learned Perceptual Image Patch Similarity）^[37]度量实现，公式如下：

$$\mathcal{L}_{LPIPS_ori} = F.LPIPS_loss(O_t, \hat{O}_t) + F.LPIPS_loss(O_{t+k}, \hat{O}_{t+k}) \quad (3-5)$$

$$\mathcal{L}_{LPIPS_swapped} = F.LPIPS(O_t, \hat{O}_{t,swapped}) + F.LPIPS(O_{t+k}, \hat{O}_{t+k,swapped}) \quad (3-6)$$

$$\mathcal{L}_{LPIPS} = 0.5 \cdot \mathcal{L}_{LPIPS_ori} + 0.5 \cdot \mathcal{L}_{LPIPS_swapped} \cdot \lambda_{Swapped_Property} \quad (3-7)$$

此外构建特征匹配损失 $\mathcal{L}_{similarity}$ ，通过源帧和目标帧的静态特征余弦相似度匹配，强制跨帧特征交互的语义对齐。计算公式为：

$$\mathcal{L}_{similarity} = F.mse(s_t, s_{t+k}) \quad (3-8)$$

量化过程产生的 $\mathcal{L}_{commit,t}$ ， $\mathcal{L}_{commit,t+k}$ ，同样加入损失函数得到损总量化损失，计算公式为：

$$\mathcal{L}_{commit} = 0.5 \cdot (\mathcal{L}_{commit,t} + \mathcal{L}_{commit,t+k}) \quad (3-9)$$

最后，总损失 $\mathcal{L}_{total}$ 由式（3-6）、式（3-9）、式（3-10）、式（3-11）四部分加权求和，具体公式为：

$$\mathcal{L}_{total} = \lambda_{commit} \cdot \mathcal{L}_{commit} + \lambda_{recons} \cdot \mathcal{L}_{recons} + \lambda_{perceptual} \cdot \mathcal{L}_{perceptual} + \mathcal{L}_{similarity} \quad (3-10)$$

其中swap_property参数（0-1可调）动态平衡时序约束强度，引入动态权重融合机制，来实现时序一致性约束。

如图3-5所示，本研究通过设计动-静态特征分离架构，有效地从连续视频帧中提取了具身通用的潜在状态，显式分离的静态、动态特征对应场景的物理不变性与可变性，为具身行为提供了坚实的基础。这种特征解耦方法不仅提高了特征的表达能力和泛化性能，还为不同机械臂平台之间的行为迁移提供了可能。




图 3-5 跨帧一致性约束

3.3 潜在状态提取重建实验设置及结果

3.3.1 潜在状态提取预训练实验设置

在基于视频无监督的机器人潜在状态提取预训练过程中，模型选用Adam优化器，将最大学习率设定为 $1.5e-4$ ，权重衰减系数保持在 $1e-4$ ，并采用线性衰减策略对学习率进行调整，并配置了8个NVIDIA H20 GPU来执行训练任务。数据批量大小(batchsize)设置为32，并经验性地为第一阶段训练30个轮次。虽然数据集中机械臂动作和本体感觉状态都是可获得的，但在潜在状态预训练期间被排除在外，仅使用第三视角图像。将在第二阶段加入机械臂动作真值。

3.3.2 潜在状态提取重建结果

为了验证前面所提出的基于视频无监督预训练的机器人潜在状态提取方法的有效性，本小节在CALVIN^[38]和SIMPLER^[39]两个仿真环境数据集中进行了实验，分别

针对Franka、Google和WidowX机械臂进行潜在状态提取与重建。图3-8展示了部分实验结果。

如图3-6所示，左侧为源帧，右侧为目标帧，每行分别展示了真值和重建结果。从图中可以看出，潜在状态提取器能够有效捕获机械臂操作中的动态特征和静态环境信息，并在重建过程中保持较高的保真度。在CALVIN环境中，Franka机械臂执行的抽屉开关、物体抓取与放置等任务中，重建帧准确还原了机械臂的动作轨迹和物体状态变化，同时保留了背景环境的静态特征。在SIMPLER环境中，Google机械臂进行的可乐罐抓取和WidowX机械臂执行的抓取胡萝卜任务中，重建结果同样展示了良好的动态捕捉能力和静态信息保留效果。




图 3-6 潜在状态提取器重建结果

具体而言，通过动-静态特征分离架构，模型能够将视频帧中的背景（如桌子、抽屉、水槽等）作为静态特征提取出来，而将机械臂的运动轨迹和物体的位姿变化作为动态特征进行编码。这种解耦方式使得潜在状态提取器在不同机械臂和不同任务场景中展现出较强的适应性和泛化能力。同时，跨帧一致性约束方法进一步增强了特

征解耦的鲁棒性，确保了动态特征在时间序列上的连贯性，避免了因特征提取不准确而导致的重建误差。

总体而言，实验结果表明所提出的潜在状态提取器能够有效地从无标注视频中提取出具身通用的潜在状态表征，为后续的具身行为学习提供了坚实的基础。

3.4 本章小结

本章构建基于视频无监督预训练的机器人潜在状态提取方法，构建编码器-解码器架构。编码器利用预训练的视觉编码器提取视频特征，经动-静态特征解耦和跨帧一致性约束，实现特征分离与信息压缩。通过残差量化变分自编码器对动态特征进行量化，得到具身通用的潜在动态状态，为后续具身行为学习提供紧凑特征表示。实验结果表明，该方法能有效从无标注视频中提取潜在状态，后续5.2节中将通过实验证明模型能够准确分离机械臂操作相关的动态特征与环境背景相关的静态特征，为机械臂具身行为学习奠定基础。

第4章 基于 Transformer 的机械臂行为学习

本章基于第三章所提取的具身通用潜在状态，进一步设计了一种基于 Transformer 架构的机械臂行为学习框架。首先介绍基于动作块的机械臂策略，然后设计多模态 Transformer 架构，构建了语言-视觉-状态三通道特征融合机制，实现了语言指令、视觉观察和机器人潜在状态的深度融合与协同推理，还引入了动态动作头架构，并在推理过程中采用时序集成的动作块策略，进一步提升了具身智能行为学习的有效性，为第五章的实验验证提供核心算法支撑。本章将对每一部分详细展开阐述。

4.1 基于动作块的机械臂策略

在模仿学习领域，策略累积误差的问题尤为显著。针对此问题，ACT^[2]创新性地通过学习动作序列而非单一动作，有效缩小了累积误差，从而实现了机械臂的高精度操作。

为了以一种与像素到动作策略相兼容的方式应对模仿学习中的复合错误，ACT 致力于降低高频收集的长轨迹的有效范围。ACT 的灵感来源于神经科学中的动作组块概念，该概念强调将单个动作组合成块并作为一个整体单元执行，这种方法不仅提高了存储效率，还优化了执行过程。具体来说，如图4-1所示，ACT模型采用了固定的动作块大小 k ，即每 k 步模型接收一次观察，并生成下一组 k 个动作，然后依次执行这些动作。这一设计使得任务的有效视界降低了 k 倍。具体而言，该策略模拟的是 $\pi_{\theta}(a_{t:t+k} | s_t)$ ，而非传统的 $\pi_{\theta}(a_t | s_t)$ 。换言之，与单步策略相比，ACT 能够更好地应对与时间相关的干扰因素，例如人类演示过程中可能出现的暂停^[40]。这些暂停使得行为不仅依赖于状态，还依赖于时间步长。通过采用动作分块方法，ACT 有效地缓解了这种混淆问题^[41]。




图 4-1 ACT 模型

然而，简单地实现动作分块可能会导致一些非最优的情况。例如，在每 k 步突然加入一个新的环境观察，这可能会引起机器人运动的不平稳。为了解决这一问题并提高动作的平滑度，ACT在每个时间步都查询策略，使得不同的动作块相互重叠。这样一来，在给定的时间步长上，就会产生多个预测动作。基于此，ACT提出了一种时间集成方法来组合这些预测动作，如图4-2所示。该时间集成方法采用指数加权方案 $\omega_i = e^{-m \times i}$ ，随时间推移，越早生成的动作在执行时占得权重就越低，其中 ω_0 代表最旧动作的权重。参数 m 决定了新观测值的合并速度，较小的 m 值意味着更快的合并速度。需要指出的是，与典型的平滑方法不同，后者通常将当前动作与相邻时间步中的动作聚合在一起，可能导致偏差。而ACT则聚合了在同一时间步预测的所有动作，有效避免了这种偏差。此外，这种方法不会引入额外的训练成本，仅会在推理时间上产生一定的计算开销。




图 4-2 动作分块和时间集成

4.2 多模态 Transformer 架构设计

4.2.1 多源输入融合机制

在具身智能系统中，多源信息的高效融合是实现复杂任务理解与精确动作执行的关键技术挑战。本研究提出了一个端到端的机械臂动作预测模型，通过多模态 Transformer 架构实现了语言指令、视觉观察和机器人潜在状态三个模态的深度特征融合与协同推理。该架构的详细实现流程如图4-3所示。




图 4-3 多模态 Transformer 架构输入

语言模态处理采用两阶段特征提取策略。首先，输入的自然语言指令通过预训练的 T5-base 模型^[42]进行编码，并通过冻结语言模型参数保留了预训练语言模型强大的语义理解能力。随后，语言特征通过可学习的线性投影层映射到统一的隐空间维度，并叠加条件嵌入实现跨模态的特征对齐。

视觉模态处理采用了两路并行的架构。第一路通过第3章设计的潜在状态提取器处理图像输入，输出潜在动态特征，随后通过潜在动态特征嵌入层映射到统一隐空间。第二路采用 SigLIP2^[25]视觉编码器提取图像块特征，然后通过图像块嵌入线性层处理，最终都统一到768维的隐空间。这种双路设计既保留了图像块级的特征保留细粒度的空间信息，又捕捉了图像包含的潜在动态状态特征，为后续的细粒度操作提供视觉基础。

为增强跨具身实体的行为迁移能力，模型从第三章预训练的潜在状态提取器中获取机器人类型嵌入，这个特殊嵌入编码了机器人类型信息（如 Google、Franka 或 WidowX 等），然后通过条件嵌入实现跨模态特征对齐，使得在序列构建时显式保留类型信息。这种处理使得模型能够自动适应不同机械臂的动力学特性。

在特征序列构建方面，首先将语言嵌入、图像块嵌入、潜在动作状态特征和机械臂类型嵌入按序拼接，组成条件输入特征。对于每个时间步，在条件输入后依次拼接动作块查询标记和动作查询标记，构成时序动作生成部分。这种显式的标记排序设计，使模型能够明确区分不同来源和作用的标记。

为构成 Transformer 完整输入序列，将条件输入特征重塑为[批次大小，条件输入标记数量，隐空间维度]的三维张量，将动作预测相关特征重塑为[批次大小，序列长

度×动作块大小，隐空间维度]的时序特征张量，其中每个时间步包含动作查询的动态信息。通过沿序列维度拼接这两类特征，模型构建了一个包含条件输入标记数量+序列长度×动作块大小个标记的完整输入序列，实现了条件输入与动态动作决策的有机统一。最后，通过层归一化处理，确保不同来源的特征在数值分布上保持一致性，为后续的Transformer编码器处理奠定基础。这种序列组织方式，既保留了各模态特征的独立性，又为跨模态注意力机制提供了结构化的交互空间。

4.2.2 分块注意力 Transformer 机制

在具身智能领域中，Transformer架构凭借其出色的表征能力，成为领域内关键技术，其核心依赖于自注意力机制（Attention Mechanism）^[43]，允许模型在计算某个位置的表示时，同时考虑序列中所有其他位置的信息，从而有效地捕捉长距离依赖关系。Transformer由多个结构相同的模块组成，每个模块都由包含编码器和解码器两部分组成，这两部分各自有对应的功能：编码器负责将输入序列映射到一个连续的表示空间中，而解码器则利用编码器的输出逐步生成输出序列。这种架构在多个领域多项任务中取得了卓越的成果。具体来说，注意力权重计算过程可以用式（3-11）表示：

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V \quad (3-11)$$

其中 Q 、 K 和 V 分别是输入序列通过与权重矩阵相乘得到的查询(Query)、键(Key)和值(Value)空间， d_k 是矩阵 K 的维度，Softmax函数将分数映射到 (0,1) 区间。

具体的在条件输入的注意力控制中，采用动态掩码生成策略。模型首先构建维度为[批次大小，1，条件输入标记数量]的条件输入的注意力掩码。该掩码默认对所有语言、视觉标记和潜在动态特征开放注意力权限，当输入变长文本序列时，通过输入数据中的语言掩码动态替换语言部分的掩码值。

时序动作的注意力约束通过三维掩码矩阵实现。基础掩码来自输入的注意力掩码，通过扩展操作沿时间维度扩展，确保前面时序无法观察后面时序内容。动作查询标记强制置零掩码，防止当前动作查询关注自身（自回归约束）导致自注意力泄露。这种分层掩码策略实现了动作生成过程中的时序因果性，确保每个时间步的预测仅依赖于历史信息。

以上约束通过分块注意力矩阵实现，如图4-4所示，最终的注意力掩码矩阵呈现出严格的分块三角形结构，其中 n_cond_tokens 表示条件嵌入标记个数， tn_tokens 表示

动作序列的长度乘以每个时间步的动作标记数量， tn_tokens 表示表示动作序列的总标记数量：

1. 条件标记区域（左上 $n_cond_tokens \times n_cond_tokens$ 块）保持全连接，允许语言和视觉跨模态充分交互；
2. 条件到动作区域（右上 $n_cond_tokens \times tn_tokens$ 块）强制零掩码，防止未来动作信息泄漏；
3. 动作序列内部（右下 $tn_tokens \times tn_tokens$ 块）维持标准的下三角因果注意力模式。

这种结构确保了：视觉-语言理解可以影响动作生成，但动作预测不会反向影响环境理解，符合机器人决策的物理因果律。




图 4-4 多模态 Transformer 的分块注意力机制

在具体Transformer过程中，模型通过分块注意力Transformer处理整合后的多模态输入。这个过程可分解为三个关键阶段：

首先，上面得到的注意力掩码会转换为模型所需的4D注意力矩阵，即将二进制掩码转换为softmax之前的logits掩码，使被屏蔽位置的注意力权重趋近于零。接着依次通过多个Transformer块进行分层注意力计算。最终，模型提取最后一层输出张量中

动作相关的输出特征重塑为[批次大小, 时间, 标记数量, 隐空间维度]的时间序列结构, 并输出。

多模态特征融合后, 模型通过多层Transformer编码器进行跨模态注意力计算。在这个过程中, 语言指令的语义信息会指导视觉特征的解读, 而视觉观察的上下文又会约束语言指令的具体实现方式。

4.3 机械臂动态动作头行为学习

针对不同机器人类型, 如图4-5所示, 模型设计了各自机器人类型独立的预测头, 在动作生成阶段会根据机械臂类型嵌入自动选择对应的预测网络, 实现机器人自适应的动作生成。




图 4-5 机械臂动态动作头行为学习

在动作预测阶段, 系统根据输入机械臂类型字符串张量创建布尔掩码, 精确分离不同机器人的特征批次。例如, 当处理Google机器人数据时, 模型仅激活Google机械臂分支, 其两层MLP网络会将768维的动作查询特征逐步压缩至384维, 最后通过对应机械臂类型手臂动作线性投影层输出6维动作向量(含3维位移、3维旋转), 1维夹爪状态通过对应机械臂类型夹爪动作线性投影层后输出。

在得到机械臂动作预测结果后, 模型采用连续动作空间的损失计算方式。由于机械臂的6自由度动作被建模为连续值, 使用Smooth L1 Loss作为损失函数, 该函数在

预测值与真实值差异较小时采用L2 Loss以获得平滑梯度，在差异较大时转为L1 Loss以避免异常值对训练造成过大影响。对于预测的夹爪动作，由于在数据处理时将夹爪动作处理为二值动作，所以采用二元交叉熵来计算1维夹爪状态的回归损失。在机械臂动作和夹爪动作的损失会分别计算后，将机械臂动作损失的权重设为100，确保模型在优化过程中优先保证机械臂位姿的预测精度，而夹爪动作则作为辅助监督信号。最终，所有损失项被汇总，通过反向传播更新模型参数，使预测动作逐步逼近真实示教数据中的连续轨迹。

4.4 动作块策略动作输出

在推理过程中，模型预测了多个时间步的动作（本研究选择预测步数=5）。若直接执行原始动作预测将面临两个主要问题：如果根据当前的观察结果连续执行所有预测步，但这未充分利用时序视觉信息，可能会导致机械臂剧烈运动；若仅执行当前帧预测的动作值单步运动会导致轨迹抖动，模型实施效果下降。

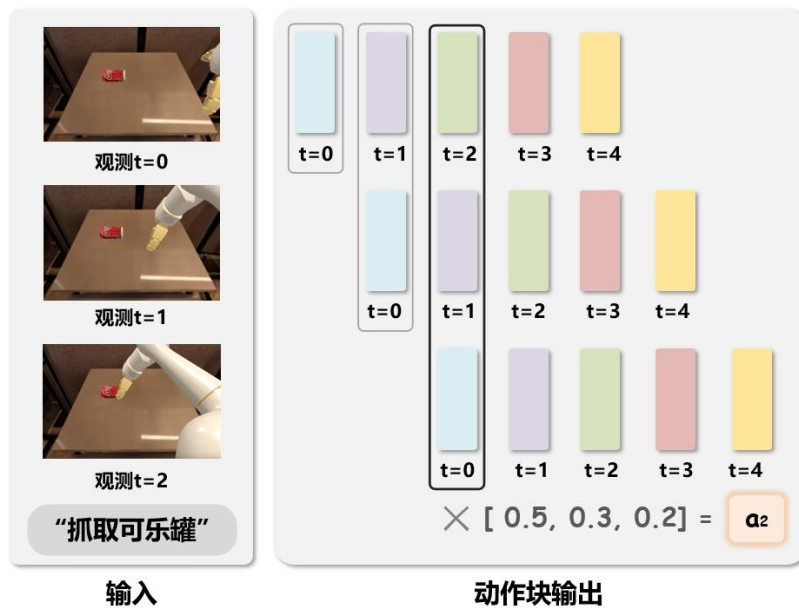


图 4-6 动作块时间集成策略

为减弱策略累积误差在机械臂执行任务中带来的负面影响，模型采用了ACT^[2]中的时间集成策略，使用预设的聚合权重将当前和过去预测的当前时间步长的动作组合在一起。具体而言，如图4-6所示，引入了一个动作缓冲区来存储当前和过去预测的动作序列。在每次预测后，将最新的动作预测添加到缓冲区中，并根据预设的聚合

权重对缓冲区中的动作进行加权求和。这一过程不仅考虑了当前时间步的动作预测，还结合了过去时间步的预测信息，从而生成更为平滑且合理的动作预测。通过这种方式，能够在保持动作连贯性的同时，减少机械臂的剧烈运动和轨迹抖动，显著提升模型的实施效果和稳定性。

4.5 本章小结

本章提出了基于Transformer架构的机械臂行为学习方法，设计了多模态Transformer架构，通过多源输入融合机制和分块注意力Transformer机制，实现了语言指令、视觉观察和机器人潜在状态的深度融合与协同推理。此外，通过引入机械臂类别嵌入层和动态动作头架构，使模型能够适应不同机械臂的动力学特性，通过动作块策略动作输出，采用时间集成策略生成平滑合理的动作预测，增强了模型在实际应用中的稳定性和可操作性。

第5章 实验验证与结果分析

本章将对构建的基于视频预训练的具身智能行为学习方法进行实验验证与分析。首先，详细阐述仿真实验的设置以及任务定义，为实验提供测试框架。此外，还进行了基于跨帧特征交换的动-静态解耦验证实验，以进一步验证所提方法在特征解耦方面的有效性。接着，通过与基线方法Moto的定量对比实验，分析所提方法在单一场景任务、未知场景泛化任务以及环境鲁棒性测试中的性能表现，验证其有效性。最后，在Franka Emika Panda 7 DoF机械臂实机平台上进一步验证方法的实际效果。

5.1 仿真实验设置

5.1.1 CALVIN

CALVIN^[38]基准中包括34个不同的任务，其特征是无约束的任务指令，涵盖了从基本的拾取和放置操作到铰接对象操纵的一系列技能。在CALVIN基准测试中，模型在一个有桌子、可打开的抽屉、彩色块、LED和灯泡的环境中控制着一个带平行夹爪的Franka Emika Panda机器人。如图5-1所示，该基准测试包括A、B、C、D四个不同的环境，每个环境都有一个用于桌面操作任务的Franka Panda机械臂。

在本研究中采用了基础单一环境的和具有挑战性的评估设置，其中基础的评估设置采用来自单一环境D的演示来训练策略，然后在同一环境D中进行策略评估，而具有挑战性的评估设置则使用来自环境A、B和C的演示来训练策略，然后在环境D中进行零样本评估，这样要求策略必须可以泛化到多种纹理、滑轨门、按钮和开关的不同位置，因为策略在训练期间从未见过测试环境和任务。评估协议包括1000个独特指令链的测试集，每个指令链由五个连续任务组成，旨在严格评估策略的泛化能力。



图 5-1 CALVIN 仿真环境

5.1.2 SIMPLER

SIMPLER^[39]作为一种用于评估真实机器人操作策略的模拟环境，其基于SAPIEN和ManiSkill2平台构建，使得能够精确地模拟物体的物理特性以及提供了丰富的预定义任务和场景，以及精细的物体模型和物理参数设置。

SIMPLER通过融入真实世界的视觉元素提升模拟环境的真实性。它利用背景替换技术，将真实背景图像与模拟的前景物体融合，并通过纹理映射将真实物体的纹理投影到模拟物体上，使其视觉效果更接近真实物体。此外，SIMPLER还调整光照条件以匹配真实环境。除了视觉匹配，SIMPLER还通过变体聚集方法创建多样化的环境变体，在背景、光照、干扰物和桌面纹理等方面进行变化，从而全面评估策略的鲁棒性和适应能力。

这些实验设置为验证所提方法在不同环境下的泛化能力和鲁棒性提供了可靠的依据。通过在SIMPLER仿真环境中执行一系列任务，可以分析不同策略在各种环境扰动下的表现。例如，在不同的光照条件下，策略是否能够保持稳定的操作性能；在存在背景或桌面纹理变化时，策略是否能够准确识别目标物体并执行操作；以及在存在干扰物的情况下，策略是否能够有效地避开干扰并完成任务。通过对这些方面的评估，SIMPLER能够验证所提方法是否能够在机械臂上展现较好的性能以及对环境变化的鲁棒性。



图 5-2 SIMPLER 仿真环境机械臂和任务

5.1.3 实验基线 Moto 方法介绍

为了验证所提出的基于视频预训练的具身智能行为学习方法的有效性，本研究选择了Moto^[43]作为实验基线方法进行对比。Moto是一种基于自回归预训练的机器人

操作学习方法，主要通过直接处理视频数据来实现精准的机器人控制。具体来说如图5-3所示，Moto方法侧重于利用自回归模型对视频数据进行建模，以预测后续的动作序列。这种方法在处理视频数据时，而没有显式地提取和利用潜在状态特征。这种方法虽然在一定程度上能够捕捉视频中的动态信息，但由于缺乏对潜在状态的显式建模，导致其在任务中的表现受到限制。

本研究选择Moto直接微调的模型作为基线方法进行对比。

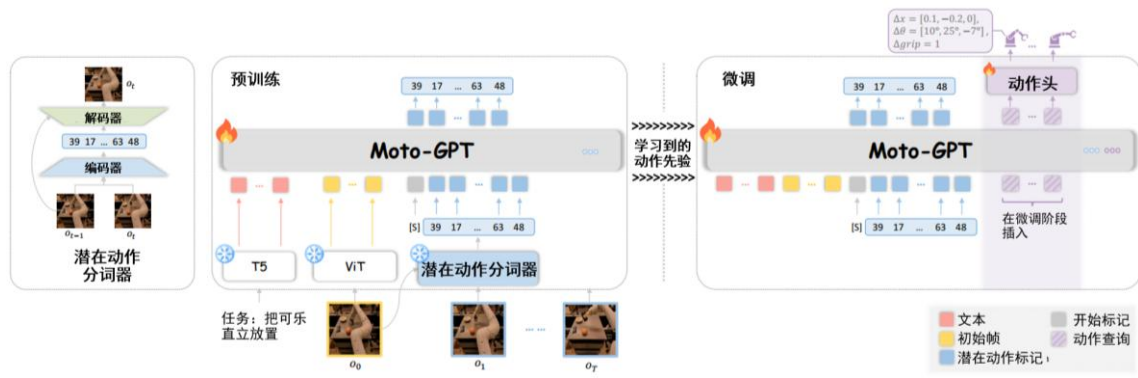


图 5-3 基线方法 Moto 方法

5.2 基于跨帧特征交换的动-静态解耦验证实验

为了验证前面提出的动-静态特征解耦架构的有效性，本研究设计了一项跨帧重建实验，旨在探究模型是否能够准确分离机械臂操作相关的动态特征与环境背景相关的静态特征。实验的核心思想是：给定相同的源帧图像（包含机械臂与物体的初始交互状态），但搭配随机不同的目标帧图像（展示不同的物体最终状态与环境背景），通过交换源帧的动态特征与目标帧的静态特征进行重建，观察重建结果是否能够保持源帧的机械臂动作状态，同时呈现目标帧的环境背景。这一设计直接验证了模型对动态操作信息与环境背景信息的解耦能力，为机械臂具身行为学习提供了底层表征支撑。

实验采用CALVIN仿真数据集中的Franka机械臂操作序列作为测试数据，该数据集包含连续的机械臂运动（接近、抓取、移动、放置）以及抽屉开关状态变化，能够充分体现动态操作与静态环境的交互。实验设置中，源帧分别选取两种不同场景：

（1）机械臂夹爪关闭推方块；（2）机械臂夹爪关闭拉开抽屉。这两组源帧在机械臂

状态和交互物体上存在显著差异，为验证动态特征提取的鲁棒性提供了多样化条件。目标帧则在数据集中随机抽取。

实验流程分为三个阶段：特征提取、特征交换与重建验证。在特征提取阶段，源帧与每组目标帧分别输入到预训练的潜在状态提取器中，通过编码器网络生成动态特征向量和静态特征向量。动态特征捕获机械臂的位姿、夹爪状态以及物体的运动轨迹，而静态特征编码了桌面纹理、抽屉位置、背景物体等环境信息。在特征交换阶段，每一组源帧的动态特征与每一组目标帧的静态特征形成混合特征表示。在重建验证阶段，混合特征输入到解码器网络中生成重建图像，通过视觉对比分析评估解耦效果，实验结果如图5-4所示。




图 5-4 跨帧特征交换实验结果

图5-4实验结果表明，两组重建图像均准确保留了源帧的机械臂位姿，同时完整呈现了目标帧的环境特征。如图5-4中红框所示，即使目标帧与源帧存在如抽屉开关状态变化，物品个数及摆放位置不同的环境布局显著差异，模型仍能保持动态特征的稳定性，证明离散化潜在状态有效过滤了与机械臂操作无关的背景噪声，为后续具身行为学习提供了具身通用的机械臂动态表征。

5.3 仿真实验结果及分析

5.3.1 CALVIN 仿真环境单一场景任务仿真实验结果及分析

在CALVIN单一场景任务基准测试中，要求机器人在每次试验中连续完成如表5-1所示的34个操作任务中的由五个连续任务组成的任务序列，旨在验证学习到的多任务语言条件策略连续完成多条语言指令的能力。在仿真环境D中包含一张带滑动门的桌子、一个抽屉、不同颜色的积木、一个开关LED的按钮和控制灯泡的开关。此实验使用来自仿真环境D中的数据进行训练，然后在仿真环境D中进行评估测试。

在预训练的初始阶段，模型选用Adam优化器，将最大学习率设定为 $1.5e-4$ ，权重衰减系数保持在 $1e-4$ ，并采用线性衰减策略对学习率进行调整，且引入了预热机制。对于预训练的两个阶段，均配置了8个NVIDIA H20 GPU来执行训练任务。数据批量大小（batchsize）均设置为32。经验性地为第一阶段训练30个轮次。虽然数据集中机械臂动作和本体感觉状态都是可获得的，但在潜在状态预训练期间被排除在外，仅使用第三视角图像。在第二阶段加入机械臂动作真值，并采用Adam优化器进行训练。优化器的最大学习率设置为 $2e-4$ ，权重衰减系数固定为 $1e-4$ 。此外，模型采用线性衰减策略对学习率进行调整，并结合预热策略以优化训练过程。基于经验，第二阶段的训练周期设定为30个轮次。

具体而言，使用来自仿真环境D中的所有视频来训练第一阶段，然后使用仿真环境D带有语言注释和动作标签的专家轨迹用于微调模型。基线方法Moto仅使用使用仿真环境D带有语言注释和动作标签的专家轨迹来微调。在本节中，选取平均任务长度这一综合指标来评价模型效果，具体数据如表5-2所示。其中，平均任务长度表示在1000个试验序列中连续完成的平均任务数。

北京理工大学本科生毕业设计（论文）

表 5-1 CALVIN 所有 34 项任务及其各自的成功标准

任务	条件
向右绕红/蓝/粉块 旋转	对象必须在 z 轴上顺时针旋转超过 60 度，同时不能在 x 或 y 轴上旋转超过 30 度
向左绕红/蓝/粉块 旋转	对象必须在 z 轴上逆时针旋转超过 60°，同时不能在 x 或 y 轴上旋转超过 30°。
向右推红/蓝/粉块	物体必须在两个框架中保持表面接触的情况下向右移动超过 10 厘米。
向左推红/蓝/粉块	物体必须在两个框架中都与表面接触的情况下向左移动超过 10 厘米。
向左/向右移动滑 动门	滑动门必须向左/右推至少 12 厘米。
打开/关闭抽屉	抽屉必须至少推入/拉出 10 厘米。
从桌子上抓取红/ 蓝/粉块	需要从桌面表面抓取目标对象，并将其至少抬升 5 厘米的高度。第一帧时，夹爪可能并未与目标对象产生接触。
从滑动门抓取红/ 蓝/粉块	需要从滑动门内抓取目标对象，且抓取后需将其提起至少 3 厘米。第一帧，夹爪有可能尚未与物体接触。
从抽屉中抓取红/ 蓝/粉块	需要从抽屉里抓取目标对象，并将其至少抬升 5 厘米的高度。第一帧时，夹爪可能并未与物体产生接触。
放置物体至滑动门 /抽屉	物体应被放置于滑动门或抽屉内部，在第一帧时，由夹爪将其提起。
将物体放入抽屉	物体要被放入抽屉中，在第一帧时，它必须与桌面表面相接触。
堆叠方块	一块积木需要放置在另一块积木的顶部，在最后一帧时，它可能不会与夹爪接触。
移除堆叠方块	一个块需要从另一个块的上部被移除，在第一帧时，它可能不与夹爪接触。
开灯/关灯	为了打开或关闭黄色灯泡，开关必须被向上或向下推动。
开 LED/关 LED	要打开或关闭绿色 LED 灯，必须按下按钮。

表 5-2 单一场景任务成功率（粗体表示最优结果）

模型	1000 个任务序列中连续完成的任务数					平均长度
	1	2	3	4	5	
Moto	0.600	0.352	0.232	0.120	0.024	1.328
本方法	0.880	0.688	0.648	0.420	0.340	2.976

表 5-2 所呈现的定量分析结果显示，在单一场景任务环境中，本研究提出的方法在整体性能方面相较于所选定的实验基线 Moto 方法展现出更优的表现。

分析其原因，本方法通过基于视频的无监督预训练，从连续帧中提取了具身通用的潜在状态表征。这种表征通过动-静态特征解耦和跨帧一致性约束，能够有效区分环境中的静态背景和动态操作。相比之下，Moto方法仅依赖有限的有标注数据进行微调，其表征能力受限于训练数据的覆盖范围，难以泛化到任务中的复杂状态变化。综上，本方法显著提升了单一场景下的任务性能。

图5-5展示了一些模型在单一场景执行任务的可视化结果。




图 5-5 单一场景执行任务可视化结果

5.3.2 CALVIN 仿真环境未知场景任务泛化仿真实验结果及分析

在CALVIN未知场景任务基准测试中，要求机器人在每次试验中连续完成如表5-1所示的34个操作任务中的由五个连续任务组成的有效任务序列，该评估旨在验证学习到的多任务语言条件策略连续完成多条语言指令的能力。

有A、B、C、D四种不同的仿真环境，每种环境都包含一张带滑动门的桌子、一个抽屉、不同颜色的积木、一个开关LED的按钮和控制灯泡的开关。如图5-1所示，环境因桌子的纹理和所有静态元素的位置而异，包括滑动门、抽屉、LED按钮和灯泡开关。在本节实验设置中，对来自环境A、B和C的数据进行训练，同时在D中进行零

样本测试。具体而言，本节使用来自环境A、B和C中的所有视频来训练潜在状态提取器，然后利用来自环境A、B和C的18k个带有语言注释和动作标签的专家轨迹用于微调模型，最后在不在训练数据集中的未知仿真环境D进行零样本测试，来评估模型对于环境变化的泛化性和鲁棒性。

在本节中，按照与上一节相同的评估指标平均任务长度，具体数据如表5-3所示。

表 5-3 未知场景任务成功率（粗体表示最优结果）

模型	1000 个任务序列中连续完成的任务数					平均长度
	1	2	3	4	5	
Moto	0.779	0.555	0.380	0.256	0.167	2.140
本方法	0.880	0.732	0.368	0.460	0.290	2.730

表5-3的定量结果表明，在未知场景任务设置下，本方法展现出比基线方法Moto更优异的泛化性能。深入分析原因，动-静态特征解耦架构有效分离了环境静态特征，使模型能适应新场景的视觉变化；其次，残差量化提取的离散潜在状态保留了跨场景通用的运动语义，确保操作逻辑的一致性。

图5-6展示了一些模型在未知场景执行泛化性任务的可视化结果。




图 5-6 未知场景执行泛化性任务可视化结果

5.3.3 SIMPLER 仿真环境多任务实验结果及分析

在SIMPLER环境中，本研究主要关注Google机械臂及其相关任务。如图5-7所示，对于Google机械臂有相关的三个任务：“抓取可乐罐”、“靠近物体”和“打开/关闭抽屉”。“抓取可乐罐”任务包括以三个不同的方向抓取和提起空可乐罐：水平放置、垂直放置和竖直放置；“靠近物体”任务将8个物体中的3个放置在桌面上，并指示机器人将指定的源物体移动到另一个物体附近作为目标；“打开/关闭抽屉”任务则要求机器人能够准确地打开和关闭上中下不同位置的抽屉。

在本节中利用Open-X-Embodiment数据集^[3]的一部分子集来训练潜在状态提取器，为了确保不同数据集之间大约1秒的均匀时间间隔，帧间隔根据每个数据集特有的记录频率进行校准，使用到数据集权重及其帧间隔如表5-4所示。在第二阶段训练和多模态Transformer时使用权重相同RT-1机器人动作数据集中的73k条带语言注释动作标记的专家轨迹和Bridge-V2机器人动作数据集的45k带语言注释动作标记的专家轨迹进行训练。



图 5-7 SIMPLER 仿真环境中 Google 机械臂任务设置

表 5-4 数据集权重及固定最小帧间隔

数据集	权重	帧间隔
RT-1	50%	3
Bridge	50%	5

表 5-5 SIMPLER 仿真环境中 Google 机械臂任务完成率（粗体表示最优结果）

		Moto	本方法
抓住 可乐罐	水平放置	0.520	0.760
	垂直放置	0.170	0.220
	竖直放置	0.560	0.490
	平均成功率	0.417	0.490
靠近物体	平均成功率	0.495	0.418
开关抽屉	开抽屉	0.046	0.027
	关抽屉	0.120	0.648
	平均完成率	0.083	0.338
总体	平均完成率	0.318	0.415

表5-5的定量结果表明，在SIMPLER仿真环境的Google机械臂任务执行中，本方法展现出比Moto基线更优异的性能。深入分析原因，量化编码的潜在状态和机械臂类型嵌入机制过滤了机械臂特定的运动学特征，保留了跨平台的通用操作语义。针对Google和WidowX机械臂设计的独立动作预测头，通过机械臂类型嵌入自动适配不同机械臂的物理学差异，验证了本方法在第三章提取的潜在动态特征具有具身通用性。

图5-8展示了模型在SIMPLER仿真器中Google机械臂完成任务的可视化结果。




图 5-8 SIMPLER 仿真环境中 Google 机械臂任务可视化结果

5.2.4 SIMPLER 仿真环境对环境变化的鲁棒性实验结果及分析

本实验旨在评估所提出的基于视频预训练的具身智能行为学习方法在面对环境变化时的鲁棒性。通过在SIMPLER仿真环境中对Google机械臂执行一系列任务，分析不同策略在各种环境扰动下的表现。这些扰动包括桌面纹理、背景、光线、干扰物以及相机视角的变化。实验结果将验证所提方法是否能够有效适应现实世界中不可避免的环境变化，同时保持较高的任务完成率。实验任务包括“抓住可乐罐”和“靠近物体”。在“抓住可乐罐”任务中，机械臂需要从不同初始位置和方向抓住并提起空可乐罐。在“靠近物体”任务中，机械臂需要将一个物体移动到另一个物体附近。

实验中引入了多种环境变化因素以测试策略的鲁棒性：

- （1）桌面纹理：改变桌面纹理图案，包括基础设置、桌面纹理1和桌面纹理2。
- （2）背景变化：更改环境背景，包括基础设置、背景1和背景2。
- （3）光线变化：调整环境光线条件，包括基础设置、光线更亮和光线更暗。
- （4）干扰物：在操作区域内增加不同数量干扰物，包括一般和很多两种情况。
- （5）相机视角变化：改变相机视角，包括基础设置、相机视角1和相机视角2。

各种环境变化因素如图5-9所示。使用平均成功率作为主要评估指标，衡量策略在不同环境变化下的性能表现。平均成功率反映了策略在多次试验中成功完成任务的比例。




图 5-9 SIMPLER 仿真环境中各种环境变化因素

表 5-6 SIMPLER 仿真环境中 Google 机械臂任务完成率（粗体表示最优结果）

			Moto	本方法
抓住 可乐罐	基础设置	平均成功率	0.520	0.570
	桌面纹理	桌面纹理 1	0.330	0.400
		桌面纹理 2	0.010	0.146
		平均成功率	0.171	0.273
	背景变化	背景 1	0.160	0.213
		背景 2	0.560	0.306
		平均成功率	0.360	0.260
	光线变化	光线更亮	0.267	0.080
		光线更暗	0.573	0.227
		平均成功率	0.416	0.153
	干扰物	一般	0.330	0.467
		很多	0.267	0.220
		平均成功率	0.298	0.344
	总体	平均成功率	0.311	0.258
靠近物体	基础设置	平均成功率	0.250	0.383
	干扰物	平均成功率	0.316	0.516
	背景变化	背景 1	0.250	0.533
		背景 2	0.383	0.400
		平均成功率	0.3165	0.4665
	光线变化	光线更亮	0.083	0.333
		光线更暗	0.430	0.367
		平均成功率	0.256	0.349
	相机视角变化	相机视角 1	0.033	0.183
		相机视角 2	0.216	0.367
		平均成功率	0.124	0.274
	总体	平均成功率	0.253	0.402
总体		平均成功率	0.282	0.330

如表5-6定量实验结果显示，本方法在大多数环境变化条件下均展现出优于Moto方法的平均成功率，这表明所提方法能够有效应对环境变化，其关键在于提取到的潜在动态特征具有较强的鲁棒性和泛化能力。这些特征能够有效过滤环境噪声，提取出与任务相关的紧凑表征，从而在不同环境条件下保持较高的任务完成率。同时，所提

方法通过视频预训练学习到的动态特征，能够更好地适应环境变化，进一步验证了方法在复杂环境下的稳定性和有效性。

5.4 量化参数对模型性能的影响分析

为深入探究残差量化变分自编码器的参数设计对模型性能的影响，本小节新增了量化深度（D）码本大小（K）的消融实验。基于第3章提出的残差量化架构，本节系统性地测试了不同参数组合在CALVIN基准单一环境任务上的表现，实验结果如表5-7所示，评价指标是平均任务长度，表示在1000个试验序列中连续完成的平均任务数。

实验设置保持第3.2.1节的动静态特征分离框架不变，调整RQ-VAE的以下参数：

- （1）量化深度：测试D=1、D=4、D=8、D=16四层配置，探究特征离散化粒度的影响；
- （2）码本大小：对比K=16、64、256三种规模，分析表征空间的容量需求。

表 5-7 量化参数对模型性能的影响（粗体表示最优结果）

	K=16	K=64	K=256
D=1	2.634	1.746	1.562
D=4	2.976	2.230	2.036
D=8	2.240	1.956	1.428
D=16	2.130	1.785	1.410

表5-7显示，当采用D=4、K=16的配置时，模型在CALVIN基准单一场景任务上的平均长度最高。分析其原因，过深的量化（L=16）会导致动态特征过度碎片化；而码本过小（K=512）会限制跨机械臂特征的表达能力。

这些发现验证了RQ-VAE在跨机械臂场景中其分层量化机制既避免了传统VQ-VAE的“码本坍缩”问题，又通过可调节的离散化程度实现了具身通用特征与具身适配性的动态平衡。

5.5 实机平台搭建

本研究选取了Franka Emika Panda 7 DoF机械臂作为实验平台。这款机械臂因其出色的稳定性、可靠性和可操作性，在机器人技术研究领域得到了广泛的应用。结合

实验室现有资源，以相关文献^[45]为参考，本研究搭建了一套VR数据采集平台。实验平台配备了固定在型材架上的奥比中光摄像头和安装在机器人末端执行器上的3D打印夹爪。奥比中光摄像头用于环境观察，其高分辨率和帧率能够实时捕捉操作场景中的视觉信息，并将视频流传输至控制系统。3D打印夹爪则用于实现对物体的抓取和操作，其设计可根据不同实验任务的需求进行调整和更换，以适应多样化的抓取要求。整个实验平台搭建在统一的操作台上，模拟桌面操作环境，确保实验的稳定性和可重复性。

在软件方面，本研究基于Meta Quest 3 VR头显，利用与之适配的控制软件，在VR界面中提供手部和手腕姿势。控制器将关键点数据传输到机器人的服务器，服务器随后转换并重定位这些关键点，以与特定的机器人设置保持一致。远程操作场景的实时视觉反馈迅速传回VR头显。该系统主要包括以下几个模块：

（1）VR界面模块采用Meta Quest 3第三方软件，为操作人员提供直观的虚拟现实操作界面，操作人员可通过该界面实时查看机器人摄像头传输的视觉信息，从而增强操作的沉浸感和准确性；

（2）手部姿态估计模块直接使用Meta Quest 3内置的手势估计器，实时捕捉操作人员手部的动作和姿态，该估计器带有两个单色摄像头，由于摄像头是内部标定的，因此不需要以前多摄像头遥控框架中所需的专门标定程序，且手势估计器集成在设备中，可以以90Hz的频率传输实时手势，通过这个模块，VR头显提供了人手和手腕所有手指的关节位置，使用这些关节位置的组合将人手姿势映射到任何给定机器人形态的机器人姿势；

（3）姿态映射模块利用腕部关键点以及食指和小指的指关节点建立一个3D坐标系，其中2D平面沿人手的手掌，第三个轴垂直于手掌，然后将腕部位置映射到机器人末端执行器位置，并将3D坐标系随时间的变化映射到末端执行器方向的变化，同时，为了检测双指夹持器的打开和关闭，利用小指和拇指之间的捏合，通过计算两个手指尖端之间的距离并设置捏合距离的阈值来检测捏合，并采用一个切换机制来打开和关闭夹持器，每次捏合表示切换到夹持器的备用状态；

（4）机械臂移动模块则使用为控制机器人手臂而建立的相同3D坐标系，将手腕的运动映射到移动机器人的动作，当手腕向前移动时，机器人手臂伸展以伸得更远，垂直的手腕运动调节机器人的高度，横向的手腕运动通过控制轮子使机器人侧向

移动，随时间变化的3D变换被映射到末端执行器方向的变化，通过食指和拇指之间的捏合来控制夹持器的打开和关闭。

5.6 实机验证及结果分析

5.6.1 实验说明

为了进一步验证基于视频预训练的具身智能行为学习方法的有效性，本研究采用 Franka Emika Panda 7 DoF 机械臂进行实验。实验场景如图 5-10 所示，实验平台包括奥比中光摄像头以及装配在机器人末端执行器上的 3D 打印夹爪，用于环境观察和执行操作任务。

实验在统一搭建的操作台进行，配备有 Franka Emika Panda 7 DoF 机械臂及奥比中光摄像头，模拟桌面操作环境。实验任务包括“打开抽屉”“擦拭桌子”等 12 项，涵盖日常操作，涉及抓取、移动、操作等多种技能。实验数据分为训练和测试两部分，训练数据采集自机械臂操作，经标注用于模型微调；测试数据通过人工评估记录成功与否。



图 5-10 实机机械臂及实验场景

5.6.2 实机训练数据采集

本课题在现实场景中精心挑选并实施了12项具有代表性的任务，涵盖了一系列典型的日常操作，具体任务如下：“打开抽屉”、“擦拭桌面”、“堆叠方块”、“打开烤箱”、“插入方形盒子”、“按下按钮”、“将水果放置于盘中”、“折叠衣服”、

“折叠衣服并放置衣服”、“从杯子中倒水”、“拉直绳子”以及“推动盒子”。为了确保数据的多样性和丰富性，为模型训练提供全面的信息支持，针对每一项任务，均采集了20条训练数据。

数据采集过程如下：首先，通过Franka Emika Panda 7 DoF机械臂执行指定任务，同时奥比中光摄像头实时捕捉操作场景的视觉信息，并将视频流传输至控制系统。机械臂执行抓取和操作动作，记录其姿态和动作信息。在VR界面中，操作人员的手部和手腕姿势通过内置的手势估计器实时捕捉，并将关键点数据传输到服务器。服务器随后转换并重定位这些关键点，以与特定的机器人设置保持一致。最后记录任务操作过程中第三视角RGB图像、机械臂末端位置和夹爪状态等数据，整理并标记时间戳以确保同步性。

5.6.3 实验结果与分析

在上述实验环境和特定任务数据收集设置下，本方法和基线方法 Moto 对比定量实验，其中 Moto 采用每一个具体任务数据直接微调模型，而本方法也采用用具体任务数据微调主干网络和 Franka 机械臂特定动作头，以提高模型对 Franka 机械臂实体的适应性。在真实场景中各项操作任务实验成功率如表 5-6 所示，真实场景任务平均成功率结果如表 5-7 所示。

表 5-6 真实场景各项操作任务实验成功率

任务	Moto	本方法
打开抽屉	0.6	0.9
擦拭桌面	0.5	0.9
堆叠方块	0.4	0.5
打开烤箱	0.5	0.9
插入方形盒子	0.5	0.7
按下按钮	0.3	0.6
把水果放进盘子里	0.6	0.7
折叠衣服	0.2	0.7
折叠衣服并放衣服	0.0	0.5
从杯子中倒水	0.0	0.6
拉直绳子	0.4	0.8
推动盒子	0.7	0.9

表 5-7 真实场景操作任务总平均成功率（粗体表示最优结果）

方法	Moto	本方法
总体	0.39	0.725

从表 5-6 的定量分析结果可以看出，在真实操作场景的环境配置中，本研究提出的方法在整体性能方面全面超越了选定的实验基线 Moto 方法。究其原因，本方法通过基于视频的无监督预训练，从大规模无标注视频中提取了具身通用的潜在状态表征。这种表征通过动-静态特征解耦和跨帧一致性约束，能够有效区分环境中的静态背景和动态操作信息，从而在真实场景中展现出更强的适应性和泛化能力。此外，本方法通过引入机械臂类型嵌入和动态动作头架构，能够更好地适配不同机械臂的动力学特性，进一步提升了模型在真实场景中的操作性能。总体而言，实验结果表明，所提出的基于视频预训练的具身智能行为学习方法在真实场景中具有显著的优势，能够有效提高机器人的操作成功率和任务完成能力。

依据表5-6所提供的数据，本研究对基线方法Moto与本研究提出的方法进行了实验结果的比较分析，并绘制了柱状图，以便更直观、清晰地呈现两者之间的差异，相关结果展示于图5-11。




图 5-11 真实场景操作任务实验成功率

机器人在真实场景中的任务操作结果如图 5-12 所示。



图 5-12 真实场景中的任务操作结果

5.7 本章小结

本章对基于视频预训练的具身智能行为学习方法进行全面实验验证与结果分析。通过在CALVIN和SIMPLER仿真环境中进行的实验，结果表明所提方法在单一场景任务、未知场景泛化性任务以及环境鲁棒性测试均优于基线方法Moto，平均任务长度和完成率均显著提升。此外，通过在Franka Emika Panda 7 DoF机械臂平台上开展

实机实验，平均成功率从0.39提升至0.725，进一步验证了该方法在真实场景中的有效性。综上所述，本课题所提方法在多个维度上均取得了显著的性能提升，证明了方法的有效性和实用性。

结 论

为了突破具身智能策略学习规模化应用中的数据瓶颈，充分利用海量视频中的无标签交互数据，进一步提升具身智能系统学习能力，本研究构建了一种基于视频预训练的具身智能行为学习方法，通过从无标注视频中提取具身通用的潜在状态表征，并结合Transformer架构实现具身智能行为学习，该方法在多个实验场景中展现了优势。本文的研究内容和成果总结如下：

1. 本研究构建了一种基于视频预训练学习的方法，通过动-静态特征解耦和跨帧一致性约束，能够准确解耦环境中的静态背景和动态操作信息，从而提取出具身通用的潜在状态。通过从无标注视频中提取潜在状态表征，有效降低了对标注数据的依赖。

2. 本研究设计了一个基于多模态Transformer架构的具身智能行为学习模型，能够有效融合语言指令、视觉观察和机器人潜在状态等多源信息，利用分块注意力机制通过动态动作头架构生成适配多平台的具身智能行为。

3. 实验部分，本研究在CALVIN和SIMPLER仿真环境以及Franka Emika Panda 7 DoF机械臂平台上进行了全面的实验验证。在仿真环境中，所提方法在单一场景任务、未知场景泛化性任务以及环境鲁棒性测试中均优于基线方法Moto，平均任务长度和完成率均显著提升。实机实验进一步验证了该方法在真实场景中的有效性，平均成功率从0.39提升至0.725。

综上所述，本课题所构建的基于视频预训练的具身智能行为学习方法能够有效提取跨平台的通用特征表示，提升具身智能行为学习有效性方面取得了显著的成果，可应用于各种机械臂操作任务中。

由于毕业设计时间有限，当前工作仍存在若干需要深入探索的方向：

第一，未利用潜在动作特征。视频数据中不仅蕴含潜在状态特征，也蕴含潜在动作特征，本文提出的模型主要关注于从视频中提取视觉特征和潜在状态表征，尚未充分利用潜在动作特征。未来的研究可以探索如何结合潜在动作特征，进一步提升模型对机器人行为的建模能力。

第二，本文的实验主要基于单视角图像输入，这限制了模型对机械臂末端精细操作信息的捕捉能力。未来的研究可以考虑采用多视角图像输入，以更全面地捕捉机械臂的操作细节，提升模型在复杂任务中的性能。

参考文献

- [1] Brohan A, Brown N, Carbajal J, et al. Rt-1: Robotics transformer for real-world control at scale[J]. arXiv preprint arXiv:2212.06817, 2022.
- [2] Zhao T Z, Kumar V, Levine S, et al. Learning fine-grained bimanual manipulation with low-cost hardware[J]. arXiv preprint arXiv:2304.13705, 2023.
- [3] O’Neill A, Rehman A, Maddukuri A, et al. Open x-embodiment: Robotic learning datasets and rx models: Open x-embodiment collaboration 0[C]. 2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 6892-6903.
- [4] Khazatsky A, Pertsch K, Nair S, et al. Droid: A large-scale in-the-wild robot manipulation dataset[J]. arXiv preprint arXiv:2403.12945, 2024.
- [5] Ye S, Jang J, Jeon B, et al. Latent action pretraining from videos[J]. arXiv preprint arXiv:2410.11758, 2024.
- [6] Jiang Y, Gupta A, Zhang Z, et al. Vima: Robot manipulation with multimodal prompts[J]. arXiv preprint arXiv:2210.03094, 2023.
- [7] Reed S, Zolna K, Parisotto E, et al. A generalist agent[J]. arXiv preprint arXiv:2205.06175, 2022.
- [8] Driess D, Xia F, Sajjadi M S M, et al. Palm-e: An embodied multimodal language model[J]. arXiv preprint arXiv:2303.03378, 2023.
- [9] Brohan A, Brown N, Carbajal J, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control[J]. arXiv preprint arXiv:2307.15818, 2023.
- [10] Kim M J, Pertsch K, Karamcheti S, et al. Openvla: An open-source vision-language-action model[J]. arXiv preprint arXiv:2406.09246, 2024.
- [11] Zhai X, Mustafa B, Kolesnikov A, et al. Sigmoid loss for language image pre-training[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 11975-11986.
- [12] Oquab M, Darcet T, Moutakanni T, et al. Dinov2: Learning robust visual features without supervision[J]. arXiv preprint arXiv:2304.07193, 2023.
- [13] Black K, Brown N, Driess D, et al. π_0 : A vision-language-action flow model for general robot control, 2024[J]. arXiv preprint arXiv:2410.24164, 2024.
- [14] Chi C, Xu Z, Feng S, et al. Diffusion policy: Visuomotor policy learning via action diffusion[J]. arXiv preprint arXiv:2303.04137, 2023.

- [15] Liu S, Wu L, Li B, et al. Rdt-1b: a diffusion foundation model for bimanual manipulation[J]. arXiv preprint arXiv:2410.07864, 2024.
- [16] Zhang K, Yun P, Cen J, et al. Generative artificial intelligence in robotic manipulation: A survey[J]. arXiv preprint arXiv:2503.03464, 2025.
- [17] Nair S, Rajeswaran A, Kumar V, et al. R3m: A universal visual representation for robot manipulation[J]. arXiv preprint arXiv:2203.12601, 2022.
- [18] Grauman K, Westbury A, Byrne E, et al. Ego4d: Around the world in 3,000 hours of egocentric video[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 18995-19012.
- [19] Ma Y J, Sodhani S, Jayaraman D, et al. Vip: Towards universal visual reward and representation via value-implicit pre-training[J]. arXiv preprint arXiv:2210.00030, 2022.
- [20] Black K, Nakamoto M, Atreya P, et al. Zero-shot robotic manipulation with pretrained image-editing diffusion models[J]. arXiv preprint arXiv:2310.10639, 2023.
- [21] Du Y, Yang S, Dai B, et al. Learning universal policies via text-guided video generation[J]. Advances in Neural Information Processing Systems, 2023, 36: 9156-9172.
- [22] Escontrela A, Adeniji A, Yan W, et al. Video prediction models as rewards for reinforcement learning[J]. Advances in Neural Information Processing Systems, 2023, 36: 68760-68783.
- [23] Bruce J, Dennis M D, Edwards A, et al. Genie: Generative interactive environments[C]. Forty-first International Conference on Machine Learning. 2024.
- [24] Chen X, Guo J, He T, et al. Igor: Image-goal representations are the atomic control units for foundation models in embodied ai[J]. arXiv preprint arXiv:2411.00785, 2024.
- [25] Tschannen M, Gritsenko A, Wang X, et al. Siglip 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features[J]. arXiv preprint arXiv:2502.14786, 2025.
- [26] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]. International Conference on Machine Learning. PmLR, 2021: 8748-8763.
- [27] Cohen G H. ALIGN: a program to superimpose protein coordinates, accounting for insertions and deletions[J]. Applied Crystallography, 1997, 30(6): 1160-1161.
- [28] Van Den Oord A, Vinyals O. Neural discrete representation learning[J]. Advances in Neural Information Processing Systems, 2017, 30.

- [29] Kingma D P, Welling M. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2022.
- [30] Bengio Y, Léonard N, Courville A. Estimating or propagating gradients through stochastic neurons for conditional computation[J]. arXiv preprint arXiv:1308.3432, 2013.
- [31] Lee D, Kim C, Kim S, et al. Autoregressive image generation using residual quantization[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11523-11532.
- [32] Esser P, Rombach R, Ommer B. Taming transformers for high-resolution image synthesis[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12873-12883.
- [33] He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9729-9738.
- [34] Le-Khac P H, Healy G, Smeaton A F. Contrastive representation learning: A framework and review[J]. Ieee Access, 2020, 8: 193907-193934.
- [35] 张重生,陈杰,李岐龙,等.深度对比学习综述[J].自动化学报,2023,49(01):15-39.
- [36] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [37] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution[C]. Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 694-711.
- [38] Mees O, Hermann L, Rosete-Beas E, et al. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334.
- [39] Li X, Hsu K, Gu J, et al. Evaluating real-world robot manipulation policies in simulation[J]. arXiv preprint arXiv:2405.05941, 2024.
- [40] Swamy G, Choudhury S, Bagnell D, et al. Causal imitation learning under temporally correlated noise[C]. International Conference on Machine Learning. PMLR, 2022: 20877-20890.
- [41] De Haan P, Jayaraman D, Levine S. Causal confusion in imitation learning[J]. Advances in Neural Information Processing Systems, 2019, 32.

- [42] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [43] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. arXiv preprint arXiv:1706.03762, 2023.
- [44] Chen Y, Ge Y, Li Y, et al. Moto: Latent motion token as the bridging language for robot manipulation[J]. arXiv preprint arXiv:2412.04445, 2024.
- [45] Iyer A, Peng Z, Dai Y, et al. Open teach: A versatile teleoperation system for robotic manipulation[J]. arXiv preprint arXiv:2403.07870, 2024.